

先端データ解析論レポート 第2回

荻野 聖也 (37-196323)

2019 年 4 月 29 日

課題 1

関数,

$$T(z) = \lambda|z| + u(\theta - z) + \frac{1}{2}(\theta - z)^2$$

について,

$$\theta - z \equiv Z$$

とすると、 $T(z) \equiv U(Z)$ にたいして,

$$U(Z) = \frac{1}{2}Z^2 + uZ + \lambda|\theta - Z|$$

この関数は微分不可能な点が存在しうるので、場合分けにより最小点を求めることにする。

(i) $\theta - Z \geq 0$ すなわち、 $Z \leq \theta$ のとき,

$$\begin{aligned} U(Z) &= \frac{1}{2}Z^2 + uZ + \lambda(\theta - Z) \\ &= \frac{1}{2}Z^2 + (u - \lambda)Z + \lambda\theta \\ &= \frac{1}{2}(Z + (u - \lambda))^2 - \frac{1}{2}(u - \lambda)^2 + \lambda\theta \end{aligned}$$

一方、(ii) $\theta - Z \leq 0$ すなわち、 $\theta \leq Z$ について,

$$\begin{aligned} U(Z) &= \frac{1}{2}Z^2 + uZ - \lambda(\theta - Z) \\ &= \frac{1}{2}(Z + (u + \lambda))^2 - \frac{1}{2}(u + \lambda)^2 - \lambda\theta \end{aligned}$$

となる。当然それぞれの関数は放物線であるが、軸の値に対して、極小点 (すなわち最小点) が変わってくる。




図1 軸による場合分け。境界 $Z = \theta$ について U は連続なので高々3通りの場合を考えれば十分。(図が汚くてすいません。)

(i) $\theta \leq -u - \lambda$ の時,
最小値は, $Z = -u - \lambda$ のとき

(ii) $-u - \lambda \leq \theta \leq -u + \lambda$ の時,
最小値は, $Z = \theta$ のときとる。

(iii) $-u + \lambda \leq \theta$ のとき,
最小値は $Z = -u + \lambda$ の時, 以上をまとめると,

$$\arg \min_Z U(Z) = \begin{cases} -u - \lambda & (\theta \leq -u - \lambda) \\ \theta & (-u - \lambda \leq \theta \leq -u + \lambda) \\ -u + \lambda & (-u + \lambda \leq \theta) \end{cases}$$

ここで, $z = \theta - Z$ より,

$$\arg \min_z T(z) = \begin{cases} \theta + u + \lambda & (\theta \leq -u - \lambda) \\ 0 & (-u - \lambda \leq \theta \leq -u + \lambda) \\ \theta + u - \lambda & (-u + \lambda \leq \theta) \end{cases}$$

ここで, $\lambda \geq 0$ より,

$$u + \theta - \lambda \leq u + \theta + \lambda$$

は常に成立する。このことから

$$\arg \min_z T(z) = \min(0, \theta + u - \lambda) + \max(0, \theta + u + \lambda)$$

宿題 2

l_1 -正則化最小二乗法の目的関数, $f(\boldsymbol{\theta})$, $g(\mathbf{z})$ はそれぞれ,

$$\begin{cases} f(\boldsymbol{\theta}) = \|\mathbf{K}\boldsymbol{\theta} - \mathbf{y}\|^2 \\ g(\mathbf{z}) = \lambda \|\mathbf{z}\|_1 \end{cases}$$

とあらわされる。ただし,

$$\mathbf{K} \equiv \begin{pmatrix} K(\mathbf{x}_1, \mathbf{x}_1) & \dots & K(\mathbf{x}_1, \mathbf{x}_n) \\ \vdots & \ddots & \vdots \\ K(\mathbf{x}_n, \mathbf{x}_1) & \dots & K(\mathbf{x}_n, \mathbf{x}_n) \end{pmatrix}$$

このとき, 拡張ラグランジュ関数 $L(\boldsymbol{\theta}, \mathbf{z}, \mathbf{u})$ は,

$$L(\boldsymbol{\theta}, \mathbf{z}, \mathbf{u}) = \frac{1}{2} \|\mathbf{K}\boldsymbol{\theta} - \mathbf{y}\|^2 + \lambda \|\mathbf{z}\|_1 + \mathbf{u}^T (\mathbf{A}\boldsymbol{\theta} + \mathbf{B}\mathbf{z} - \mathbf{c}) + \frac{1}{2} \|\mathbf{A}\boldsymbol{\theta} + \mathbf{B}\mathbf{z} - \mathbf{c}\|^2$$

解の更新式は,

$$\begin{cases} \boldsymbol{\theta}^{(k+1)} = \arg \min_{\boldsymbol{\theta}} L(\boldsymbol{\theta}, \mathbf{z}^{(k)}, \mathbf{u}^{(k)}) \\ \mathbf{z}^{(k+1)} = \arg \min_{\mathbf{z}} L(\boldsymbol{\theta}^{(k+1)}, \mathbf{z}, \mathbf{u}^{(k)}) \\ \mathbf{u}^{(k+1)} = \mathbf{u}^{(k)} + \mathbf{A}\boldsymbol{\theta}^{(k+1)} + \mathbf{B}\mathbf{z}^{(k+1)} - \mathbf{c} \end{cases}$$

であらわされる。 $\boldsymbol{\theta}$ について,

$$\frac{\partial L}{\partial \boldsymbol{\theta}} = \mathbf{K}^T \mathbf{K}\boldsymbol{\theta} - \mathbf{K}^T \mathbf{y} + \mathbf{A}^T \mathbf{u} + \mathbf{A}^T \mathbf{A}\boldsymbol{\theta} + \mathbf{A}^T (\mathbf{B}\mathbf{z} - \mathbf{c}) = \mathbf{0}$$

を解くと, $\mathbf{K}^T = \mathbf{K}$ より,

$$\boldsymbol{\theta} = (\mathbf{K}^2 + \mathbf{A}^T \mathbf{A})^{-1} (\mathbf{K}^T \mathbf{y} - \mathbf{A}^T \mathbf{u} - \mathbf{A}^T (\mathbf{B}\mathbf{z} - \mathbf{c}))$$

以下，講義同様に

$$\begin{cases} \mathbf{A} = \mathbf{I} \\ \mathbf{B} = -\mathbf{I} \\ \mathbf{c} = \mathbf{0} \end{cases}$$

とすると，

$$\boldsymbol{\theta} = (\mathbf{K}^2 + \mathbf{I})^{-1}(\mathbf{K}\mathbf{y} + \mathbf{z} - \mathbf{u})$$

なので，

$$\begin{aligned} \boldsymbol{\theta}^{(k+1)} &= \arg \min_{\boldsymbol{\theta}} \mathbf{L}(\boldsymbol{\theta}, \mathbf{z}^{(k)}, \mathbf{u}^{(k)}) \\ &= (\mathbf{K}^2 + \mathbf{I})^{-1}(\mathbf{K}\mathbf{y} + \mathbf{z}^{(k)} - \mathbf{u}^{(k)}) \end{aligned}$$

また， \mathbf{z} に対して

$$\mathbf{L} = \frac{1}{2} \|\mathbf{K}\boldsymbol{\theta} - \mathbf{y}\|^2 + \lambda \|\mathbf{z}\|_1 + \mathbf{u}^T(\boldsymbol{\theta} - \mathbf{z}) + \frac{1}{2} \|\boldsymbol{\theta} - \mathbf{z}\|^2$$

の最小点を求める。

$$\arg \min_{\mathbf{z}} \mathbf{L} = \arg \min_{\mathbf{z}} \left\{ \lambda \|\mathbf{z}\|_1 + \mathbf{u}^T(\boldsymbol{\theta} - \mathbf{z}) + \frac{1}{2} \|\boldsymbol{\theta} - \mathbf{z}\|^2 \right\}$$

各基底（添え字 i とする）成分について，

$$\arg \min_{z_i} \left\{ \lambda |z_i| + u_i(\theta_i - z_i) + \frac{1}{2}(\theta_i - z_i)^2 \right\} = \max(0, \theta_i + u_i - \lambda) + \min(0, \theta_i + u_i - \lambda)$$

なので（ただし，宿題 1 の結果を用いた。），

$$\arg \min_{\mathbf{z}} \mathbf{L} = \max(0, \boldsymbol{\theta} + \mathbf{u} - \lambda \mathbf{1}) + \min(0, \boldsymbol{\theta} + \mathbf{u} - \lambda \mathbf{1})$$

これより， \mathbf{z} に関する更新式は

$$\begin{aligned} \mathbf{z}^{(k+1)} &= \arg \min_{\mathbf{z}} \mathbf{L}(\boldsymbol{\theta}^{(k+1)}, \mathbf{z}, \mathbf{u}^{(k)}) \\ &= \max(0, \boldsymbol{\theta}^{(k+1)} + \mathbf{u}^{(k)} - \lambda \mathbf{1}) + \min(0, \boldsymbol{\theta}^{(k+1)} + \mathbf{u}^{(k)} - \lambda \mathbf{1}) \end{aligned}$$

最後に， \mathbf{u} についてであるが，これは更新された $\boldsymbol{\theta}^{(k+1)}$ および $\mathbf{z}^{(k+1)}$ を用いて，

$$\mathbf{u}^{(k+1)} = \mathbf{u}^{(k)} + \boldsymbol{\theta}^{(k+1)} - \mathbf{z}^{(k+1)}$$

以上をまとめると，

$$\begin{cases} \boldsymbol{\theta}^{(k+1)} = (\mathbf{K}^2 + \mathbf{I})^{-1}(\mathbf{K}\mathbf{y} + \mathbf{z}^{(k)} - \mathbf{u}^{(k)}) \\ \mathbf{z}^{(k+1)} = \max(0, \boldsymbol{\theta}^{(k+1)} + \mathbf{u}^{(k)} - \lambda \mathbf{1}) + \min(0, \boldsymbol{\theta}^{(k+1)} + \mathbf{u}^{(k)} - \lambda \mathbf{1}) \\ \mathbf{u}^{(k+1)} = \mathbf{u}^{(k)} + \boldsymbol{\theta}^{(k+1)} - \mathbf{z}^{(k+1)} \end{cases}$$

データについて

データは前回のレポート同様に，

$$f(x) = \frac{\sin(\pi x)}{\pi x} + 0.1x$$

を真の関数とし，サンプル $\{(x_i, y_i)\}_{i=1}^n$ は，

$$y_i = f(x_i) + \varepsilon_i$$

ただし，ノイズ ε_i は正規分布

$$\varepsilon_i \sim N(0, \sigma^2)$$

に従うものとする。サンプル数 n は， $n = 50$ とする。




図 2 スパース回帰による実行結果

結果

実行結果を図 2 に示す。コードについては補填か添付したファイルを参考にしてください。

補填

コードについて示す。但し、使用した言語は Python3.7.1 である。

Listing 1 宿題 2 のソースコード

```

1  ##Requirement
2  import numpy as np
3  import matplotlib.pyplot as plt
4  import random
5
6  def func(x, with_noise=True):
7      """基本方程式
8      Args:
9          x(float):座標 x
10         with_noise(boolean):ノイズ入れるかどうか
11     Return:
12         fx(float):座標に対応する xy(with_noise?)
13     """
14     noise = 0.05 * np.random.normal(loc=0., scale=1.) if with_noise else 0
15     return np.sin(np.pi*x)/np.pi/x+0.1*x + noise
16
17 def get_sample(x_min=-3., x_max=3., num_sample=50):
18     """サンプル生成
19     Args:
20         x_min(float):座標の最小値 x_default=-3.
21         x_max(float):座標の最大値 x_default=3.
22         num_sample(int):サンプルの生成数 (=dim(theta))_default=50
23
24     Return:
25         x_lst(list(float)):座標の集合 x
26         fx_lst(list(float)):座標の集合 y
27     """
28     x_lst = np.linspace(x_min, x_max, num_sample)
29     fx_lst = np.array([func(x, with_noise=True) for x in x_lst])
30     return x_lst, fx_lst

```

```

31
32 def get_gauss_kernel(x, c, h):
33     return np.exp(-(x-c)**2/2/h**2)
34
35 def calc_admm(zk, uk, K_mat, y_vec, lam):
36     """反復法により交互方向乗数法の更新式を解く
37     〃〃〃Arg:
38     〃〃〃〃zk(ndarray(float))〃前状態の z
39     〃〃〃〃uk(ndarray(float))〃前状態の u
40     〃〃〃〃K_mat(ndarray(ndarray(float)))〃ガウスカーネル行列←サンプルに依存 x
41     〃〃〃〃y_vec(ndarray(float))〃サンプル fx
42     〃〃〃〃lam(float)〃正則化パラメータ
43     〃〃〃Return:
44     〃〃〃〃theta_next(ndarray(float))〃次状態の theta
45     〃〃〃〃u_next(ndarray(float))〃次状態の u
46     〃〃〃〃z_next(ndarray(float))〃次状態の z
47     〃〃〃"""
48     n = len(y_vec)
49     I = np.eye(n)
50     theta_next = np.dot(np.linalg.inv((np.dot(K_mat,K_mat)+I)), np.dot(K_mat,y_vec)+zk-uk)
51     max_factor = np.vstack((np.zeros(n), theta_next+uk-lam*np.ones(n)))
52     min_factor = np.vstack((np.zeros(n), theta_next+uk+lam*np.ones(n)))
53     z_next = np.max(max_factor,axis=0) + np.min(min_factor,axis=0)
54     u_next = uk+theta_next-z_next
55     return theta_next, z_next, u_next
56
57 def calc_lasso(X, Y, h, lam):
58     """スパース回帰を解く
59     〃〃〃Arg:
60     〃〃〃〃X(ndarray(float))〃サンプルの座標の集合 x
61     〃〃〃〃Y(ndarray(float))〃サンプルの座標の集合 y
62     〃〃〃〃h(float)〃ガウス幅
63     〃〃〃〃lam(float)〃正則化パラメータ
64     〃〃〃〃z0(float)〃の初期状態 z〃default=0
65     〃〃〃〃u0(float)〃の初期状態 u〃default=0
66
67     〃〃〃Return:
68     〃〃〃〃x_pred(ndarray(float))〃予測系の座標←予測しているわけではない x
69     〃〃〃〃y_pred(ndarray(float))〃予測された fx(座標に対応 x)
70     〃〃〃"""
71     n = len(Y)初期化
72     #
73     zk = np.zeros(n)
74     uk = np.zeros(n)
75     k_matrix = np.empty((n,n))ガウスカーネルマトリックス
76     #
77     for i in range(len(k_matrix)):
78         for j in range(len(k_matrix[0])):
79             k_matrix[i][j] = get_gauss_kernel(X[i], X[j], h)
80     #による更新 ADMM
81     for _ in range(10):
82         theta_next, z_next, u_next = calc_admm(zk, uk, k_matrix, Y, lam)
83         zk = z_next
84         uk = u_next生成フェーズ
85     #
86     def get_pred_fx(x):
87         fx_pred = 0
88         for i in range(n):
89             k=get_gauss_kernel(x, X[i], h)
90             fx_pred += theta_next[i]*k
91         return fx_pred
92     x_pred = np.linspace(-3, 3, 1000)
93     fx_pred = np.empty_like(x_pred)

```

```

94     for i in range(len(x_pred)):
95         fx_pred[i] = get_pred_fx(x_pred[i])
96
97     return x_pred, fx_pred
98
99
100 def plot_graph(x_sample, y_sample, x_pred, y_pred, y_acc):
101     plt.clf()
102     plt.scatter(x_sample, y_sample, label="sample", c='red', marker='o')
103     plt.plot(x_pred, y_pred, label="prediction", c='blue')
104     plt.plot(x_pred, y_acc, label="true", c="green")
105     plt.legend()
106     plt.savefig(r"C:\Users\msy-o\Documents\lecture\summer\data_analytics\report\03\output\lasso.png")
107     plt.show()
108     return None
109 if __name__ == "__main__":
110     x_sample, y_sample = get_sample()
111     x_pred, y_pred = calc_lasso(x_sample, y_sample, 0.3, 0.1)
112     y_acc = np.empty_like(x_pred)
113     for i in range(len(y_acc)):
114         y_acc[i] = func(x_pred[i], with_noise=False)
115     plot_graph(x_sample, y_sample, x_pred, y_pred, y_acc)

```
